Laboratório 8: Dados Relacionais com Polars

Letícia da Costa Venancio - 250125

```
library(reticulate)
```

```
py_require("polars")
py_require("matplotlib")
```

```
import polars as pl
```

Leitura dos dados

```
basics = pl.read_csv("title.basics0.tsv.gz", separator="\t", null_values=r"\N")

ratings = pl.read_csv("title.ratings.tsv.gz", separator="\t", null_values=r"\N")

principals = pl.read_csv("title.principals0.tsv.gz", separator="\t", null_values=r"\N")
```

1. Quais são os 5 filmes com as maiores notas (averageRating)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```
maiores_notas = (basics.filter(pl.col("titleType") == "movie")
                       .join(ratings, on="tconst", how="inner")
                       .sort(by=["averageRating", "numVotes"], descending=[True, True])
                       .select(["primaryTitle", "averageRating", "numVotes"])
                       .head(5))

print(maiores_notas)
```

```
shape: (5, 3)

 primaryTitle               averageRating   numVotes
 ---                        ---             ---
 str                        f64             i64

 Kaveri                     10.0            1023
 Kurukku                    10.0            451
 Jedal Dar Omghe 30 Metri   10.0            142
 Sargashte                  10.0            134
 Gorgeous Rascal            10.0            115
```

2. Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```
genero_freq = (basics.filter(pl.col("titleType") == "movie")
                     .join(ratings.filter(pl.col("averageRating") > 8),
                                          on="tconst", how="inner")
                     .filter(pl.col("genres").is_not_null())
                     .with_columns(pl.col("genres").str.split(","))
                     .explode("genres")
                     .group_by("genres")
                     .agg(pl.len().alias("frequencia"))
                     .sort("frequencia", descending=True)
                     .head(1))

print(genero_freq)
```

```
shape: (1, 2)

 genres        frequencia
 ---           ---
 str           u32

 Documentary   10564
```

3. Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
participacao_atores = (principals
                       .filter(pl.col("category")
                       .is_in(["actor", "actress"]))
                       .join(basics.filter(pl.col("titleType") == "movie"),
                                           on="tconst", how="inner")
                       .join(ratings.filter(pl.col("averageRating") > 7.5),
                                            on="tconst", how="inner")
                       .group_by("nconst")
                       .agg(pl.col("tconst").n_unique().alias("total_filmes"))
                       .sort("total_filmes", descending=True)
                       .head(3))

print(participacao_atores)
```

```
shape: (3, 2)

 nconst      total_filmes
 ---         ---
 str         u32

 nm0004660   199
 nm0595934   155
 nm3183374   124
```

```
lubridate::now(tzone = "America/Sao_Paulo")
```

```
[1] "2026-10-15 01:13:12 -03"
```