Laboratório 9

Letícia da Costa Venancio - 250125

```
library(reticulate)
py_require("polars")
py_require("pyarrow")
py_require("plotnine")
```

1. Importe o conjunto de dados diamonds, cujo arquivo está disponível no website da disciplina.

Importei o arquivo da biblioteca plotnine.data, como foi mencionado no laboratório que ela estava disponível.

```
import polars as pl
from plotnine import *
from plotnine.data import diamonds as diamonds

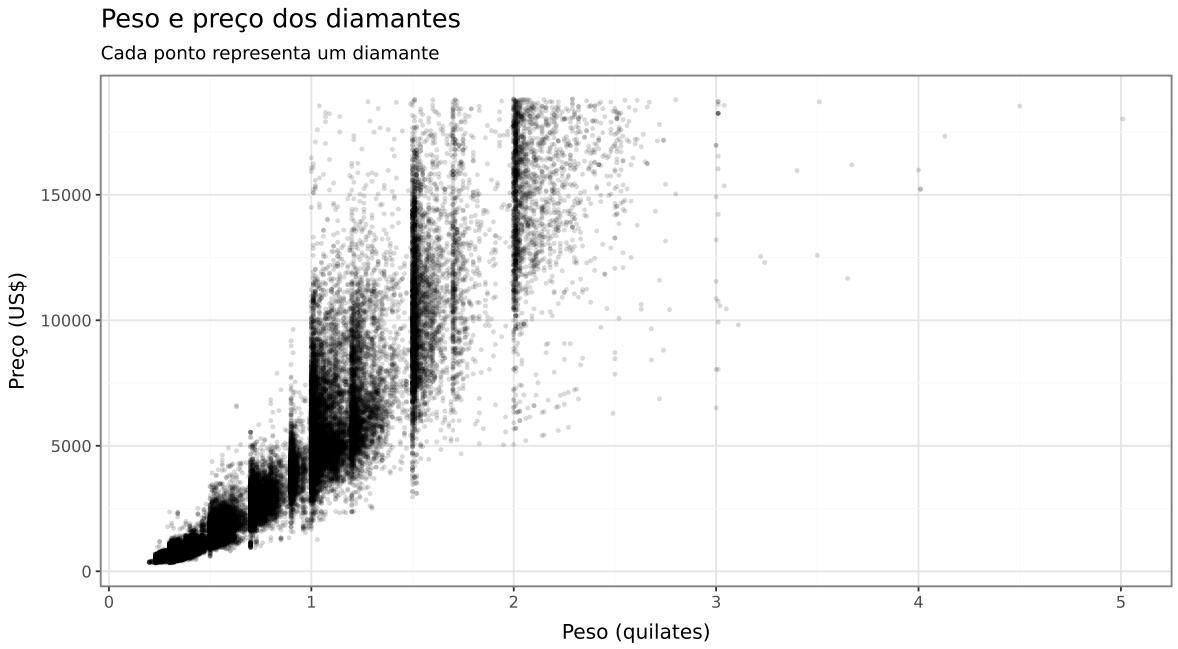
diamonds = pl.DataFrame(diamonds)
diamonds.head()
```

carat f64	cut cat	color cat	clarity cat	depth f64	table f64	price i64	x f64	y f64	z f64
0.23	”Ideal”	”E”	”SI2”	61.5	55.0	326	3.95	3.98	2.43
0.21	”Premium”	”E”	”SI1”	59.8	61.0	326	3.89	3.84	2.31
0.23	”Good”	”E”	”VS1”	56.9	65.0	327	4.05	4.07	2.31
0.29	”Premium”	”I”	”VS2”	62.4	58.0	334	4.2	4.23	2.63
0.31	”Good”	”J”	”SI2”	63.3	58.0	335	4.34	4.35	2.75

2. Crie uma visualização de dados que descreva a associação existente entre as variáveis peso (carat) e preço (price). Que ações você tomou para garantir que você produziu um gráfico de boa qualidade? Escreva um parágrafo comunicando os seus achados.

```
graf2 = (
   ggplot(diamonds)
    + aes(x="carat", y="price")
    + geom_point(alpha=0.15, size=0.5)
    + theme_bw()
    + labs(
        x="Peso (quilates)",
        y="Preço (US$)",
        title="Peso e preço dos diamantes",
        subtitle="Cada ponto representa um diamante"
    )
    + theme(
        figure_size=(9, 5),
        plot_title=element_text(size=14),
        plot_subtitle=element_text(size=10),
        axis_title=element_text(size=11)
    )
)

graf2
```



O gráfico permite observar que diamantes mais pesados apresentam preços maiores. Entretanto, há variação nos preços de diamantes com pesos semelhantes, indicando que o peso não explica sozinho todas as diferenças de preço.

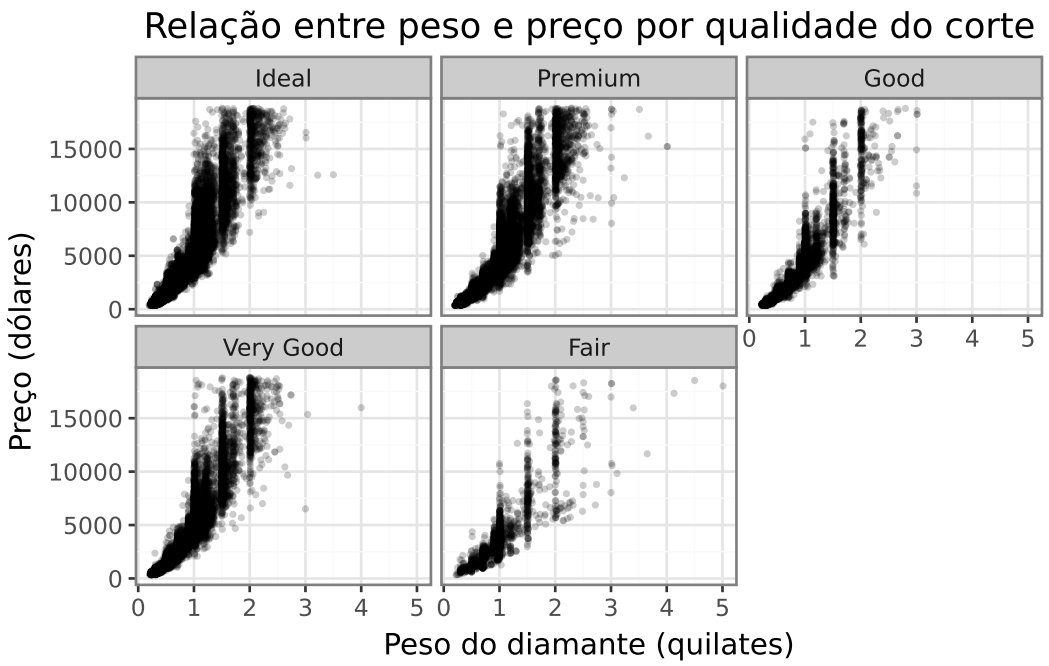
Para melhorar a qualidade da visualização, foi escolhido um gráfico de dispersão, também foi reduzida a opacidade dos pontos para diminuir a sobreposição e foram adicionados título e rótulos aos eixos. Dessa forma, o gráfico fica mais claro e facilita a identificação da tendência geral.

3. A relação identificada na questão anterior é a mesma relação presente nos diferentes cortes de diamantes? Crie uma visualização que demonstre seus achados eficientemente. Descreva sua conclusão em um parágrafo.

```
graf3 = (
    ggplot(diamonds)
    + aes(x="carat", y="price")
    + geom_point(alpha=0.2, size=0.5)
    + facet_wrap("cut", ncol=3)
    + theme_bw()
    + labs(
        x="Peso do diamante (quilates)",
        y="Preço (dólares)",
```

```
        title="Relação entre peso e preço por qualidade do corte"
    )
)

graf3
```



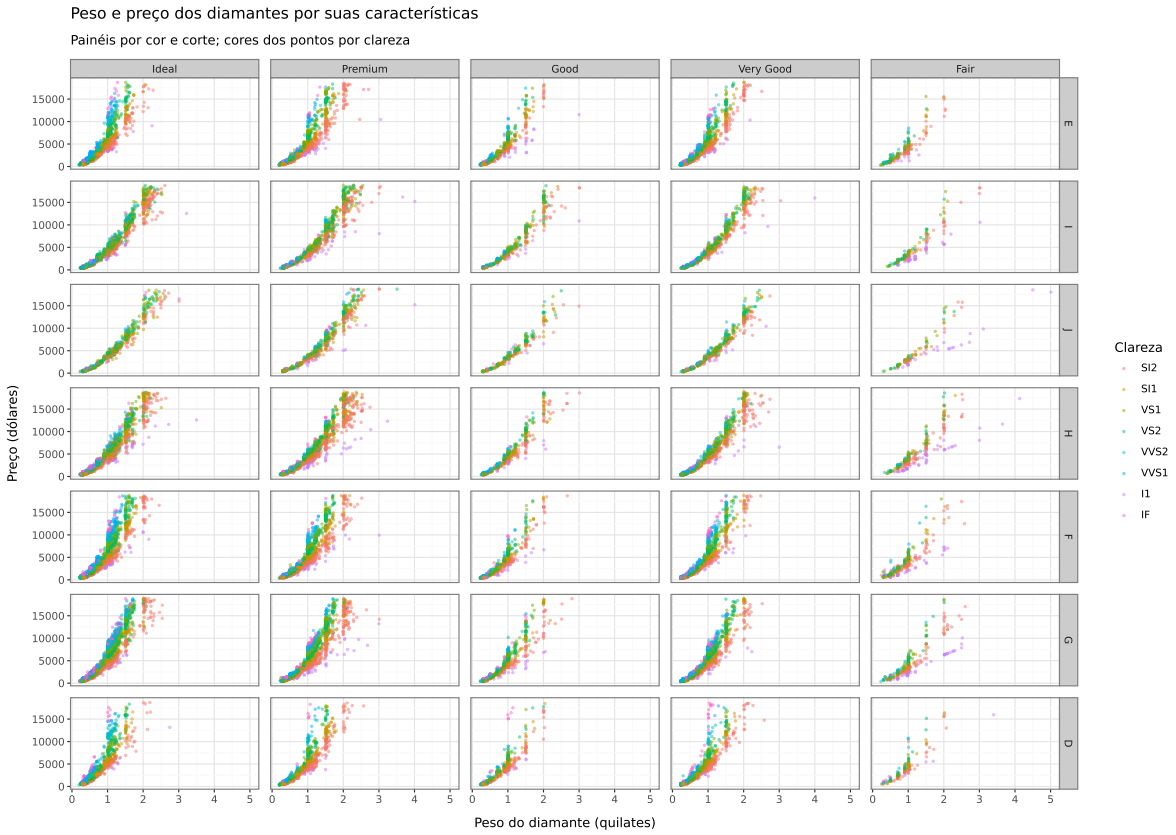
A associação entre peso e preço é positiva nas diferentes categorias de corte, visto que diamantes mais pesados tendem a apresentar preços maiores. Entretanto, a distribuição dos pontos varia entre os painéis, indicando diferenças na distribuição de peso e preço entre as categorias. A utilização de facetas facilita essa comparação, pois permite observar cada grupo separadamente, mantendo a mesma escala dos eixos.

4. Crie uma visualização que mostre a relação entre preço e peso do diamante, considerando as diferentes combinações de qualidade de corte, cor e clareza do diamante. Quais foram as dificuldades encontradas? A relação entre preço e peso é a mesma para diferentes configurações de diamantes?

```
graf4 = (
    ggplot(diamonds)
    + aes(x="carat", y="price", color="clarity")
    + geom_point(alpha=0.5, size=0.6)
```

```
    + facet_grid("color", "cut")
    + theme_bw()
    + labs(
        x="Peso do diamante (quilates)",
        y="Preço (dólares)",
        color="Clareza",
        title="Peso e preço dos diamantes por suas características",
        subtitle="Painéis por cor e corte; cores dos pontos por clareza"
    )
    + theme(figure_size=(14, 10))
)

graf4
```



A principal dificuldade encontrada foi representar tantas combinações sem tornar o gráfico muito poluído. Existem cinco categorias de corte, sete de cor e oito de clareza, o que pode levar até 280 combinações possíveis. O uso de facetas e cores permite representar essas dimensões, embora alguns painéis apresentem sobreposição de pontos.

A relação entre peso e preço continua positiva nas diferentes configurações, mas a distribuição dos preços varia entre os grupos. Portanto, a relação não é necessariamente igual para todas as combinações de corte, cor e clareza. O gráfico permite identificar padrões e diferenças entre os grupos, mas não é suficiente, por si só, para determinar o efeito isolado de cada característica sobre o preço.

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```